

Real-Time Sales & Inventory Analytics Pipeline

Batch ETL ▪ PySpark Transformations ▪ Airflow ▪ Kafka/Redpanda ▪ Streamlit

PostgreSQL

PySpark

Airflow

Kafka / Redpanda

Streamlit

Final Project — ETL & Pipeline Orchestration

Alhousseynou Ndiaye

MSc Data Engineering & Artificial Intelligence

Project Objective

Business Problem

Retail companies generate sales data from different stores and channels.

This data must be:

- ▶ collected
- ▶ cleaned
- ▶ transformed
- ▶ monitored
- ▶ visualized


Project Goal

Build a complete data pipeline that combines:

- ▶ historical batch processing
- ▶ PySpark transformations
- ▶ workflow orchestration
- ▶ real-time streaming
- ▶ business dashboard

Main question: how can raw sales data become useful business insights?

Global Architecture



Batch ETL with PySpark


Batch Flow

1. Generate synthetic CSV data
2. Load raw data into PostgreSQL
3. Transform data with PySpark
4. Load staging and analytics tables
5. Display results in Streamlit

Main tables

- ▶ `raw.sales_batch`
- ▶ `staging.sales_clean`
- ▶ `analytics.daily_sales_summary`

Airflow Orchestration



Real-Time Streaming Pipeline

Streaming Flow

1. Producer generates live sales events
2. Events are sent to Redpanda / Kafka
3. Consumer reads the events
4. Events are inserted into PostgreSQL
5. Real-time metrics are updated

Main components

- ▶ kafka_producer.py
- ▶ sales_stream topic
- ▶ kafka_consumer.py

Producer / Consumer Demo

```
(.venv) PS C:\Users\DNWABOOK\etl-final-project> python scripts/kafka_consumer.py
Vente consommée et insérée sale_id=STREAM-70EA59F4890F amount=381.0
Vente consommée et insérée sale_id=STREAM-5B718E4D66CB amount=4838.35
Vente consommée et insérée sale_id=STREAM-E19A07827441 amount=1688.52
Vente consommée et insérée sale_id=STREAM-79D947B64D5F amount=86.58
Vente consommée et insérée sale_id=STREAM-BF1D3823D78B amount=165.4
Vente consommée et insérée sale_id=STREAM-10E57741B748 amount=2889.46
Vente consommée et insérée sale_id=STREAM-BA331E8571E4 amount=228.6
Vente consommée et insérée sale_id=STREAM-212997077882 amount=980.5
Vente consommée et insérée sale_id=STREAM-0D0A5C7C0F4 amount=1828.47
Vente consommée et insérée sale_id=STREAM-E8E98F6E96F8 amount=588.92
Vente consommée et insérée sale_id=STREAM-8074CDFAB0DA amount=3160.23
Vente consommée et insérée sale_id=STREAM-B0B2AD358119 amount=548.93
Vente consommée et insérée sale_id=STREAM-C4ED6772778 amount=588.92
Vente consommée et insérée sale_id=STREAM-3EE496FF345E amount=582.18
Vente consommée et insérée sale_id=STREAM-D7CDFAF04D72 amount=75.22
Vente consommée et insérée sale_id=STREAM-9DC574281440 amount=1962.52
Vente consommée et insérée sale_id=STREAM-8FC389737F90 amount=2453.15
Vente consommée et insérée sale_id=STREAM-CE928697866C amount=286.75
Vente consommée et insérée sale_id=STREAM-5955861A9F63 amount=535.15
Vente consommée et insérée sale_id=STREAM-DC78408623F0 amount=2453.15
Vente consommée et insérée sale_id=STREAM-7F280AF6E635 amount=626.15
Vente consommée et insérée sale_id=STREAM-0CC39D9587EE amount=981.55
Vente consommée et insérée sale_id=STREAM-3240056275D1 amount=1218.98
Vente consommée et insérée sale_id=STREAM-7493893FFAD7 amount=683.19
Vente consommée et insérée sale_id=STREAM-338C261F6E7A amount=1286.38
Vente consommée et insérée sale_id=STREAM-7011ED1ACBDA amount=5901.96

(.venv) PS C:\Users\DNWABOOK\etl-final-project> python scripts/kafka_producer.py
: '2026-06-15 23:35:42'}
Message envoyé topic=sales_stream partition=0 offset=75
Événement 77/100 produit : {'sale_id': 'STREAM-001893FD4AD6', 'product_id': 'P007', 'store_id': '5008', 'customer_id': 'CUST-404194', 'quantity': 1, 'unit_price': 146.55, 'total_amount': 146.55, 'payment_method': 'mobile_money', 'sale_timestamp': '2026-06-15 23:35:43'}
Message envoyé topic=sales_stream partition=0 offset=76
Événement 78/100 produit : {'sale_id': 'STREAM-C1B8FF7984F', 'product_id': 'P012', 'store_id': '5003', 'customer_id': 'CUST-892170', 'quantity': 2, 'unit_price': 101.17, 'total_amount': 202.34, 'payment_method': 'card', 'sale_timestamp': '2026-06-15 23:35:44'}
Message envoyé topic=sales_stream partition=0 offset=77
Événement 79/100 produit : {'sale_id': 'STREAM-7265E33FF9FF', 'product_id': 'P024', 'store_id': '5007', 'customer_id': 'CUST-638825', 'quantity': 4, 'unit_price': 967.67, 'total_amount': 3870.68, 'payment_method': 'cash', 'sale_timestamp': '2026-06-15 23:35:45'}
Message envoyé topic=sales_stream partition=0 offset=78
Événement 80/100 produit : {'sale_id': 'STREAM-971761A2F5FB', 'product_id': 'P022', 'store_id': '5005', 'customer_id': 'CUST-B48850', 'quantity': 2, 'unit_price': 86.58, 'total_amount': 173.16, 'payment_method': 'card', 'sale_timestamp': '2026-06-15 23:35:46'}
```

Real-Time Sales & Inventory Analytics Pipeline

Dashboard de suivi des ventes batch et temps réel.
Les données batch sont orchestrées avec Airflow, et les ventes temps réel passent par Kafka / Redpanda.

 [Rafraîchir maintenant](#)

Vue globale batch

Chiffre d'affaires total	Nombre de commandes	Articles vendus	Panier moyen
1,587,056.41 €	1,000	2,983	1,587.06 €


Dashboard — Historical Sales

Analyse des ventes historiques

Évolution du chiffre d'affaires par jour




Nombre de commandes par jour




Dashboard — Products and Categories

Répartition du chiffre d'affaires par catégorie



Quantités vendues par produit



Dashboard — Real-Time Kafka Metrics

CA temps réel récent

137,456.86 €


Ventes temps réel

100

Panier moyen temps réel

1,374.57 €

Évolution du chiffre d'affaires temps réel



Technical Validation — PostgreSQL Batch

```
o (.venv) PS C:\Users\DYNABOOK\etl-final-project> docker exec -it etl_postgres psql -U etl_user -d etl_sales_db
psql (16.11 (Debian 16.11-1.pgdg13+1))
Type "help" for help.

etl_sales_db=# SELECT COUNT(*) FROM raw.sales_batch;
count
-----
  1000
(1 row)

etl_sales_db=# SELECT COUNT(*) FROM staging.sales_clean;
count
-----
  1000
(1 row)

etl_sales_db=# SELECT COUNT(*) FROM analytics.daily_sales_summary;
count
-----
   303
(1 row)

etl_sales_db=# SELECT COUNT(*) FROM analytics.product_performance;
count
-----
    25
(1 row)
```

Technical Validation — Real-Time Metrics

```
etl_sales_db=# SELECT
    metric_timestamp,
    total_revenue,
    total_orders,
    average_basket
FROM analytics.realtime_sales_metrics
ORDER BY metric_timestamp DESC
LIMIT 10;
```

metric_timestamp	total_revenue	total_orders	average_basket
2026-06-15 21:36:06.932918	137456.86	100	1374.57
2026-06-15 21:36:05.937999	137206.40	99	1385.92
2026-06-15 21:36:04.902961	136124.40	98	1389.02
2026-06-15 21:36:03.864994	135803.31	97	1400.03
2026-06-15 21:36:02.851662	130579.66	96	1360.20
2026-06-15 21:36:01.846849	130286.56	95	1371.44
2026-06-15 21:36:00.853784	128197.10	94	1363.80
2026-06-15 21:35:59.84077	127892.30	93	1375.19
2026-06-15 21:35:58.837267	124021.62	92	1348.06
2026-06-15 21:35:57.834511	123841.31	91	1360.89

(10 rows)

```
etl_sales_db=# \q
```

Conclusion

What was built

- ▶ Batch ETL
- ▶ PySpark transformations
- ▶ Airflow DAG
- ▶ Kafka streaming
- ▶ Streamlit dashboard

Business value

- ▶ centralized sales data
- ▶ automated processing
- ▶ clean analytics tables
- ▶ real-time monitoring
- ▶ actionable KPIs

Next steps

- ▶ dbt models
- ▶ cloud deployment
- ▶ Spark Structured Streaming
- ▶ anomaly detection
- ▶ forecasting

Thank you
Questions?